HỌC PHẦN: KHAI PHÁ DỮ LIỆU — BÀI THỰC HÀNH

ĐỀ 01 — Dự đoán giá nhà & phân cụm khu dân cư California

Mô tả đề bài

Bộ dữ liệu *California Housing* (Điều tra dân số California năm 1990) gồm 20.640 khu dân cư, mỗi khu được mô tả bởi vị trí (`longitude`, `latitude`), tuổi nhà, số phòng, số phòng ngủ, dân số, số hộ, thu nhập trung vị (`median_income`), vị trí so với biển (`ocean_proximity`) và giá nhà trung vị (`median_house_value`).

Dữ liệu: `https://raw.githubusercontent.com/ageron/handson-ml2/master/datasets/housing/housing.csv`

Sinh viên thực hiện hai nhiệm vụ: (1) xây dựng mô hình **dự đoán giá nhà** của một khu dân cư; (2) **phân cụm** các khu dân cư để tìm ra các phân khúc kinh tế – xã hội và các vùng đô thị tập trung.

Bài làm nộp dưới dạng một notebook Jupyter đã chạy đầy đủ; các phần giải thích viết trực tiếp trong notebook.

Yêu cầu

1. Khám phá dữ liệu (EDA)

- Mô tả tổng quan dữ liệu: kiểu dữ liệu, thống kê mô tả, giá trị thiếu, biến phân loại.
- Phân tích phân phối của biến mục tiêu và các đặc trưng; chỉ ra các điểm bất thường (ngoại lai, giá trị bị chặn trên, nhóm có quá ít mẫu).
- Phân tích mối quan hệ giữa các đặc trưng và giá nhà (tương quan, biểu đồ phân tán, theo nhóm `ocean_proximity`).
- Trực quan hoá dữ liệu theo vị trí địa lý và nhận xét.
- Rút ra các nhận định từ EDA và nêu ảnh hưởng của chúng tới bước tiền xử lý và lựa chọn mô hình.

2. Tiền xử lý dữ liệu

- Xử lý giá trị thiếu, mã hoá biến phân loại, chuẩn hoá dữ liệu khi cần.
- Tạo thêm các đặc trưng có ý nghĩa (ví dụ: số phòng trên mỗi hộ).
- Chia tập huấn luyện / kiểm tra hợp lý và đảm bảo không rò rỉ dữ liệu.

3. Học có giám sát — Dự đoán giá nhà

- Xây dựng và so sánh tối thiểu các mô hình: **Linear Regression**, **Decision Tree**, **Random Forest**, kèm một mô hình cơ sở để đối chứng.
- Lựa chọn tham số cho mô hình bằng cross-validation; với Decision Tree phải khảo sát ảnh hưởng của **độ sâu cây (`max_depth`)** tới underfitting/overfitting.
- Đánh giá mô hình bằng các độ đo phù hợp (RMSE, MAE, R^2).
- **Giải thích** lựa chọn mô hình cuối cùng và các tham số đã chọn; phân tích tầm quan trọng của các đặc trưng.

4. Học không giám sát — Phân cụm khu dân cư

- Áp dụng **K-Means** trên các đặc trưng kinh tế – xã hội (không dùng giá nhà); xác định số cụm **K** bằng **phương pháp Elbow** và **Silhouette score**, giải thích lựa chọn K.
- Mô tả và đặt tên cho từng cụm; đối chiếu các cụm với giá nhà và vị trí địa lý.
- Áp dụng **DBSCAN** trên toạ độ địa lý để tìm các vùng dân cư tập trung; giải thích cách chọn tham số `eps` và `min_samples`.
- So sánh K-Means và DBSCAN, giải thích thuật toán nào phù hợp hơn cho từng mục đích.

5. Kết luận

- Tóm tắt kết quả chính của hai nhiệm vụ.
- Nêu hạn chế của dữ liệu / mô hình và hướng cải tiến.